운영 장애 진단 에이전트의 근거 기반 검증·검색·조사 안정성 개선

01 주제 · 25초

기존 문제 ①

답변 검증이 형식만 검사
3회 실패하면 강제 합격

기존 문제 ②

매뉴얼을 키워드로 선택
못 찾으면 db-down 기본값

기존 문제 ③

조사 하나가 실패하면
성공한 자료까지 버림

→ 근거 대조 검증 · 의미 기반 매뉴얼 검색 · 부분 실패 격리 · 근거를 보여주는 화면

기능 개선: 검증 · 검색 · 실패 처리

02 핵심 개선 3가지 · 35초

① 근거 대조 검증

시스템명·CPU·메모리 %
오차 0.5%p 허용
불일치 사유로 재작성
3회 실패 → 실패 안내

② 의미 기반 매뉴얼 검색

로컬 임베딩 + 코사인 유사도
MCP 도구로 제공
점수 낮거나 차이 작으면 미확정
후보·점수를 화면에 표시

③ 부분 실패 격리

작업별 예외 수집
성공한 자료 유지
시간 제한 · 실패 대상 표시
자료 없으면 검증 불가 종료

수집(모니터링·매뉴얼 검색) → 작성 → 근거 대조 → 통과 / 재작성 / 실패 안내

구조·안정성 개선과 스스로 찾은 약점

03 추가 개선 4가지 · 35초

④ 조사 서브에이전트

research → 2개로 분리
monitoring_agent
runbook_agent
supervisor가 병렬 분배

⑤ 대상 시스템 해석

없는 시스템을 auth-service로
바꾸지 않고 조사 실패로 표시
이름이 없을 때만 기본값,
사용했음을 알림

⑥ 검증 규칙 2차

동의어·표·'각각' 지원
임계치·부정 수치 제외
수치 인용 시에만
시스템명 요구

⑦ 노드 모듈화

graph.py 425줄 → 58줄
nodes/ 6개 모듈
동작 변경 없음
(테스트로 확인)

개선이 만든 약점(틀린 값 통과·런북 문장 오탐)을 평가를 다시 돌려 스스로 찾아 고침

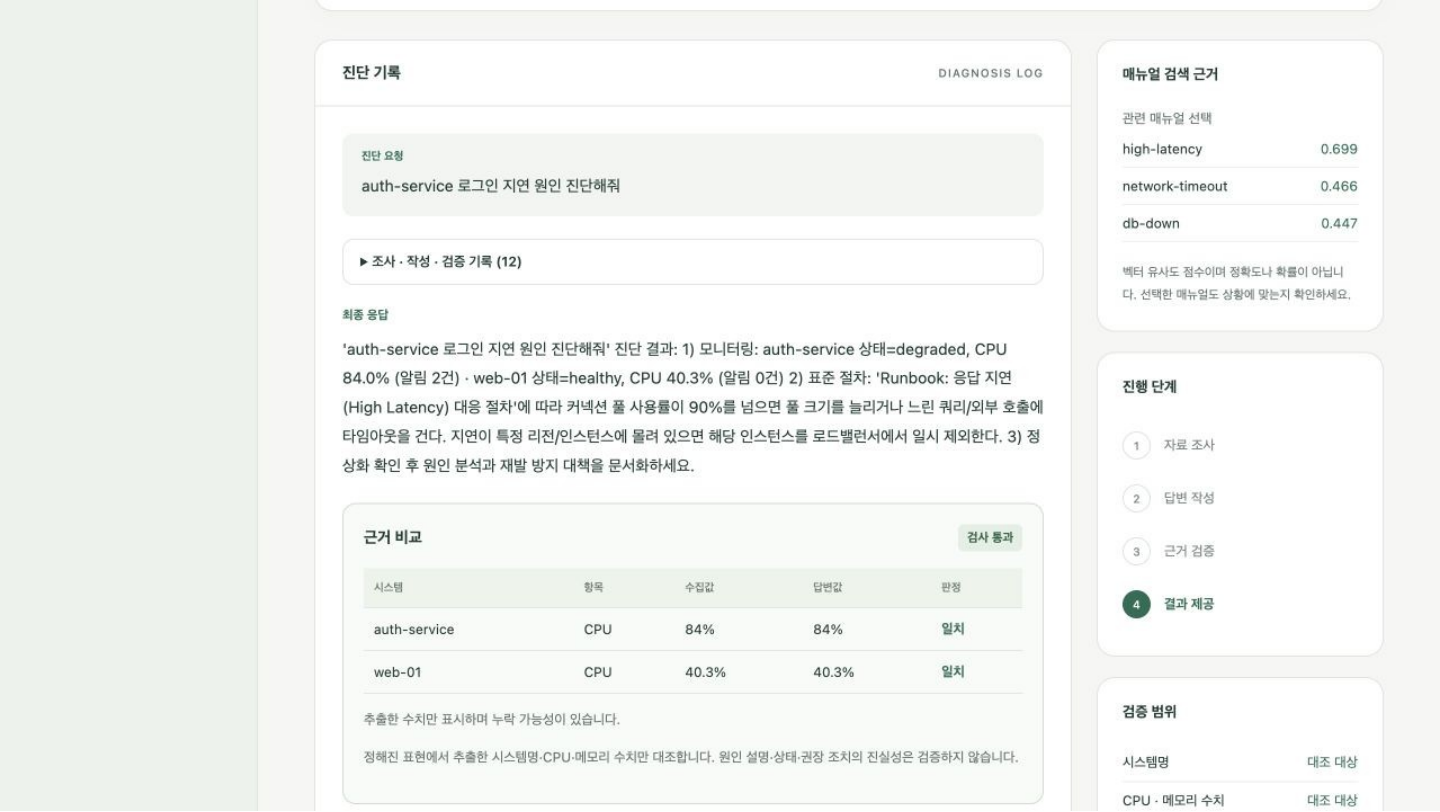
사용한 기술: 제공 기반과 내 변경

04 기술 요소 · 35초

기술	제공받은 기반	내가 바꾼 것
LangGraph	route→⋯→finalize 흐름	검증 실패 분기 · 재조사 판단 분리
Multi-Agent	단일 그래프 supervisor 노드	research → 서브에이전트 2개 (ADR-10)
MCP · RAG 흐름	모니터링 도구·매뉴얼 조회	검색 도구 추가 → 검색→작성 (ADR-02)
병렬 조사	asyncio.gather	부분 실패 격리 · 시간 제한
모듈화 · DI · 테스트	agent/ 패키지 · SupervisorDeps 주입	nodes/ 분리 · 서브에이전트 DI · 테스트 6종
FastAPI · SSE · SQLite	서버 · 진행 스트리밍 · 세션	초안 토큰 차단 · metadata 확장
모델 분리 · LangSmith	fast/quality · 추적 코드	효과 측정 · 추적 트리 확인(평가는 안 함)

최종 실행 화면

05 최종 실행 · 10초



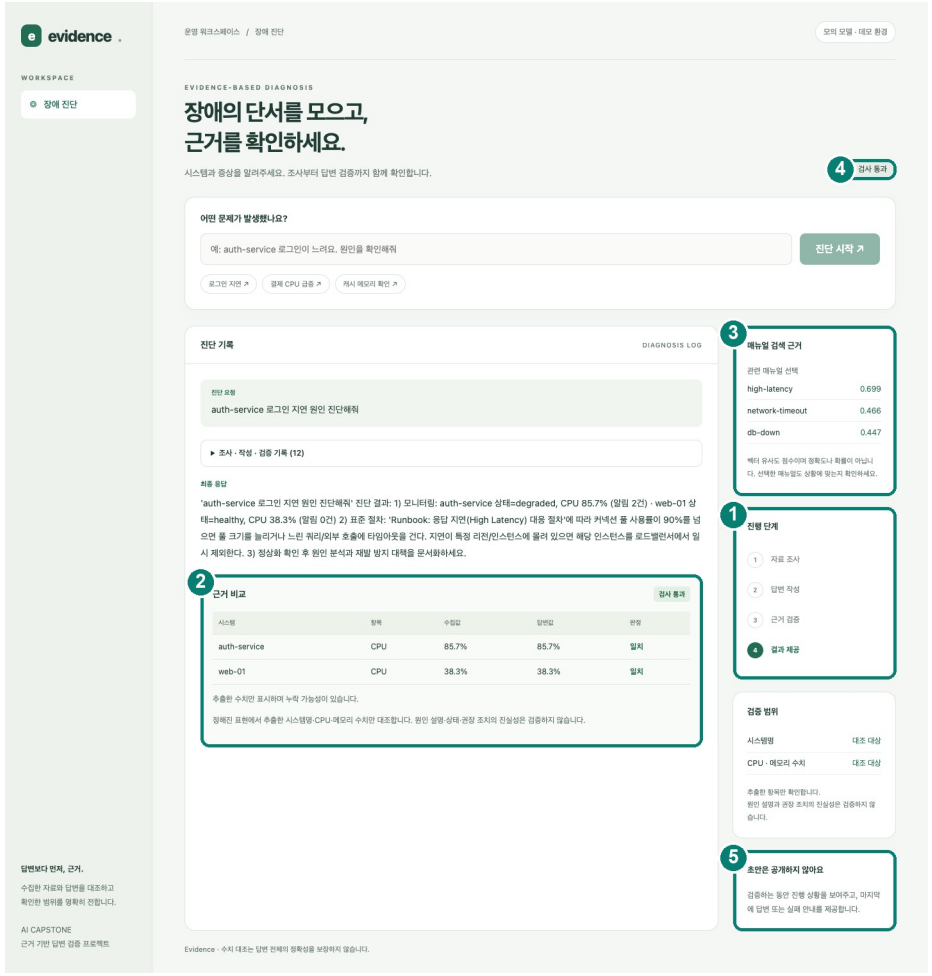
화면에서 확인할 것

① 최종 답변: 초안은 비공개
② 근거 비교표: 수집값 vs 답변값
③ 매뉴얼 검색 근거: 후보·점수
④ 검증 범위: 대조한 항목만 명시

실제 서버+MCP+임베딩, 작성 모델은 모의(정해진 응답)

화면 개선: 검증 근거를 확인할 수 있게

06 화면 설계 의도 · 제공받은 Vue 화면을 근거 확인 중심으로 개선 · 35초

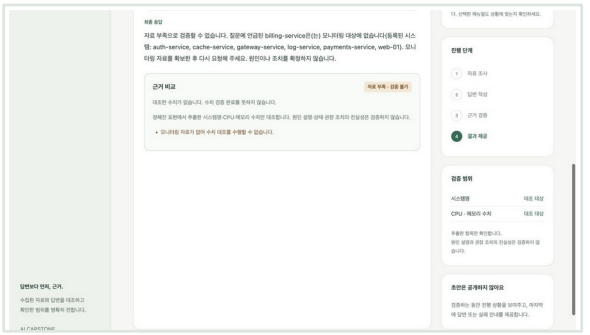


1. **진행 단계**
   기다리는 동안 무엇을 하는지 보인다
2. **수집값 ↔ 답변값 비교표**
   통과했다는 말만 믿지 않고 직접 비교한다
3. **검색 후보와 유사도**
   어떤 매뉴얼이 선택됐는지 확인한다 (점수는 확률이 아님)
4. **상태 구분**
   정상, 검증 실패, 자료 부족을 다르게 안내한다
5. **초안 비공개**
   반려될 초안은 먼저 보여주지 않는다

검증 실패



자료 부족 · 검증 불가



선택 전후 비교 화면

07 같은 틀린 답변, 같은 질문 · 35초

개선 전 (legacy 검증)



→ 틀린 CPU(100.5%·54.8%)가 근거 표시 없이 최종 응답

개선 후 (근거 대조 검증)



핵심 차이

통과시키던 틀린 답변을 "검증 실패"로 막고, 사유와 실제 수집값을 함께 안내

전후 수치 비교

08 실측 결과 · 40초

답변 검증 (기존 17개)	**오류 차단 2/9 → 9/9**	정상 통과 8/8 → 8/8 (오탐 해소)
검증 규칙 (표적 28개)	**오류 차단 6/14 → 14/14**	정상 통과 7/14 → 14/14 (자체 사례)
매뉴얼 선택 (14개)	**기대 일치 6/14 → 12/14**	무관 질문 미선택 0/2 → 2/2
Ollama 실모델 (4질문×1회)	**작성 시도 1.0 → 1.0회**	시간은 개선 전과 비슷 (42.6s ↔ 43.3s)

소규모 자체 평가 · 실모델 최신 비교는 legacy와 grounded · 실행 간 시간 변동이 커서 시간 개선은 주장하지 않음

보너스: 실측 수치 3가지

09 동시 실행 · 모델 분리 · 조기 종료 · 20초

동시 실행 (측정)

병렬 0.36~0.37초
직렬 1.07~1.08초
약 3배 (5회)
※ 0.35초/태스크는
원본의 시뮬레이션

모델 분리 (측정·추정)

분리 $0.0027
전부 quality $0.0067
약 59% 절감 (추정)
※ 토큰=글자수/4,
단가는 가정값

조기 종료 (직접 추가)

근거 0건이면 작성 생략
응답 36.6s → 1.2~2.7s
작성 모델 호출 1 → 0회
※ billing-service 질문
3회, 단일 질문

앞 둘은 제공 구조의 효과 "측정", 마지막은 직접 추가한 비용 최적화

한계와 트레이드오프

10 한계 · 마무리 · 35초

남은 한계

표현 변화 → 누락·오탐 (규칙이
틀린 값을 통과시킨 적 2회)
원인 설명·알림 인용 미검증
서브에이전트: LLM 판단 없음
소규모 자체 평가 · OpenAI 미검증

트레이드오프

시스템명 요구 완화 ↔ 수치 없는
답변은 대조 없이 통과
초안 비공개 ↔ 토큰 스트리밍 포기
부분 자료 진행 ↔ 한계 표시 필요
모듈화 ↔ 성능 이득 없음

검사 통과 = 추출한 수치의 대조 결과 ≠ 답변 전체가 사실이라는 보장

향후 개선: 사용자에게 되묻는 대상 확인 · 독립 평가셋 · LLM 판정 병행 · LangSmith 기반 평가 · 임베딩 검색 확장(문서 증가 시 인덱스 전략)