근거 기반
장애 진단 에이전트 개선

수집한 자료와 다른 답변을
그대로 통과시키지 않도록

검증 · 검색 · 조사 안정성

김하연

AI Capstone | 2026.10

질문

**“로그인이 느려요.
원인을 진단해줘.”**

자료 수집 → 근거 대조

일치하면 응답 · 부족하면 중단

형식 검증만으로는 수치 오류를 걸러내지 못함

수집한 자료	모델이 쓴 답변	기존 검증 결과
auth-service · CPU	auth-service · CPU	통과
40%	99%	길이 + 번호만 확인

설명용 예시 · 실제 평가 수치 아님

형식 검사 30자 이상 + “1)” 포함

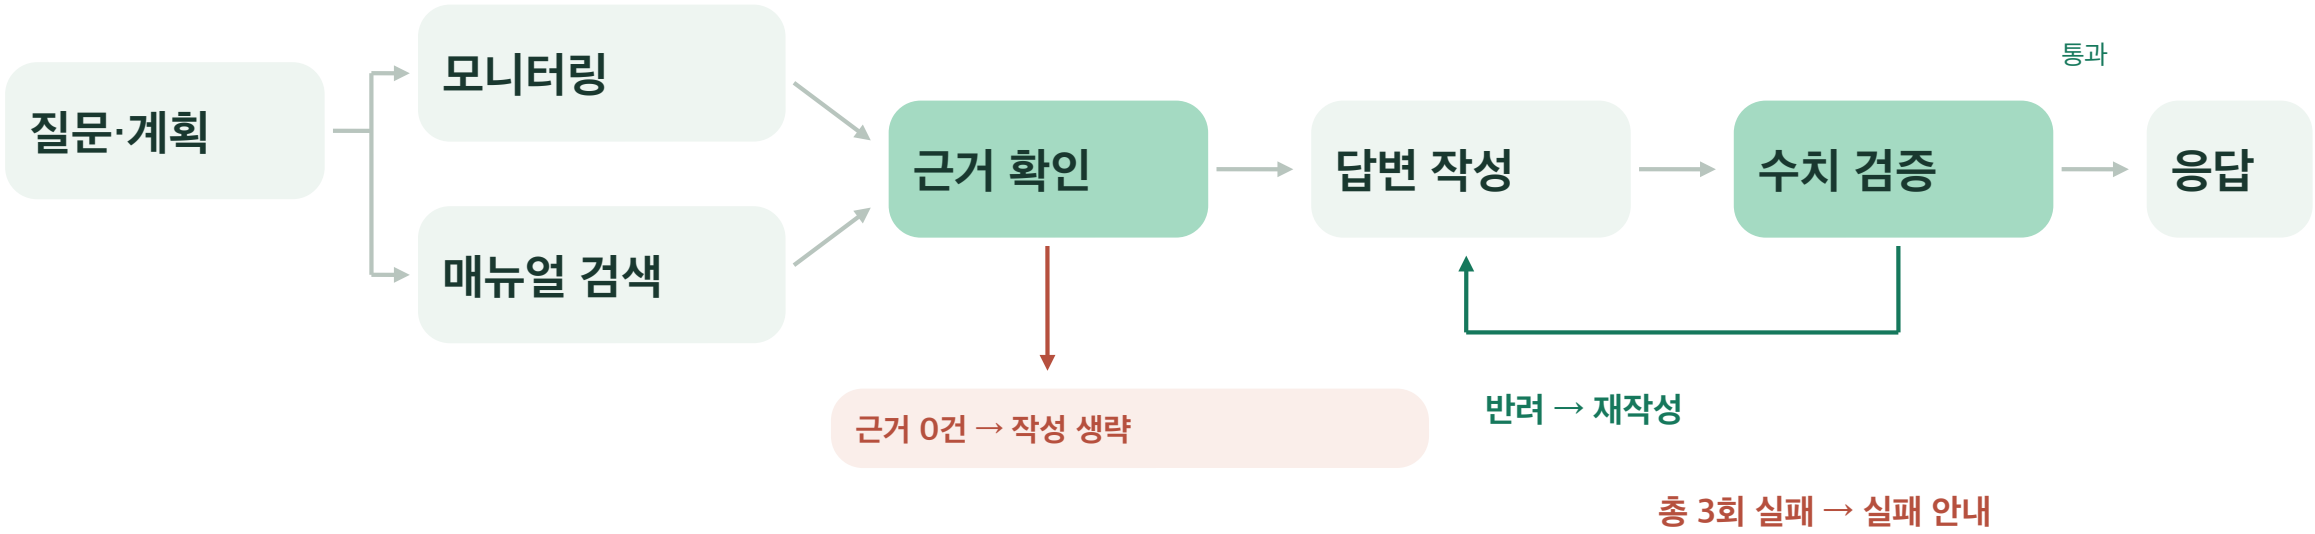
3회 실패해도 강제 합격

근거 수집부터 답변 출력까지 전 구간 개선

검증	길이·번호 확인	→	**시스템별 수치 대조** 불일치 사유 → 재작성 / 총 3회 실패 → 중단
검색	키워드·기본값 선택	→	**매뉴얼 의미 검색** 점수가 낮거나 후보 차이가 작으면 선택 보류
조사	한 작업 실패 시 중단	→	**성공한 자료 유지** 실패 대상 안내 / 근거 0건이면 작성 생략

추가 보완 대상 시스템명 구분 · 역할별 모듈 분리 · 단위·회귀 테스트

근거 확인 및 실패 분기를 반영한 처리 흐름



Multi-Agent

조사 서브그래프 2개
독립 LLM 추론·협상은 아님

MCP · RAG

도구 연결 → 의미 검색
선택한 본문으로 답변 작성

모듈화 · 의존성 주입

역할 분리 · 테스트 도구 교체
단위·회귀 테스트 포함 6종

제공 기반: LangGraph·서버·세션 | 직접 개선: 조사 분리·검색·검증·실패 분기 | LangSmith: 실행 추적만 확인

최종 답변과 확인 근거를 함께 제공

최종 응답

'auth-service 로그인 지연 원인 진단해줘' 진단 결과: 1) 모니터링: auth-service 상태=degraded, CPU 84.0% (알림 2건) · web-01 상태=healthy, CPU 40.3% (알림 0건) 2) 표준 절차: 'Runbook: 응답 지연 (High Latency) 대응 절차'에 따라 커넥션 풀 사용률이 90%를 넘으면 풀 크기를 늘리거나 느린 쿼리/외부 호출에 타임아웃을 건다. 지연이 특정 리전/인스턴스에 몰려 있으면 해당 인스턴스를 로드밸런서에서 일시 제외한다. 3) 정상화 확인 후 원인 분석과 재발 방지 대책을 문서화하세요.

근거 비교 검사 통과

시스템	항목	수집값	답변값	판정
auth-service	CPU	84%	84%	일치
web-01	CPU	40.3%	40.3%	일치

추출한 수치만 표시하며 누락 가능성이 있습니다.

정해진 표현에서 추출한 시스템명·CPU·메모리 수치만 대조합니다. 원인 설명·상태·권장 조치의 진실성은 검증하지 않습니다.

01 **최종 답변**

초안 비공개, 검증 후 제공

02 **수집값 ↔ 답변값**

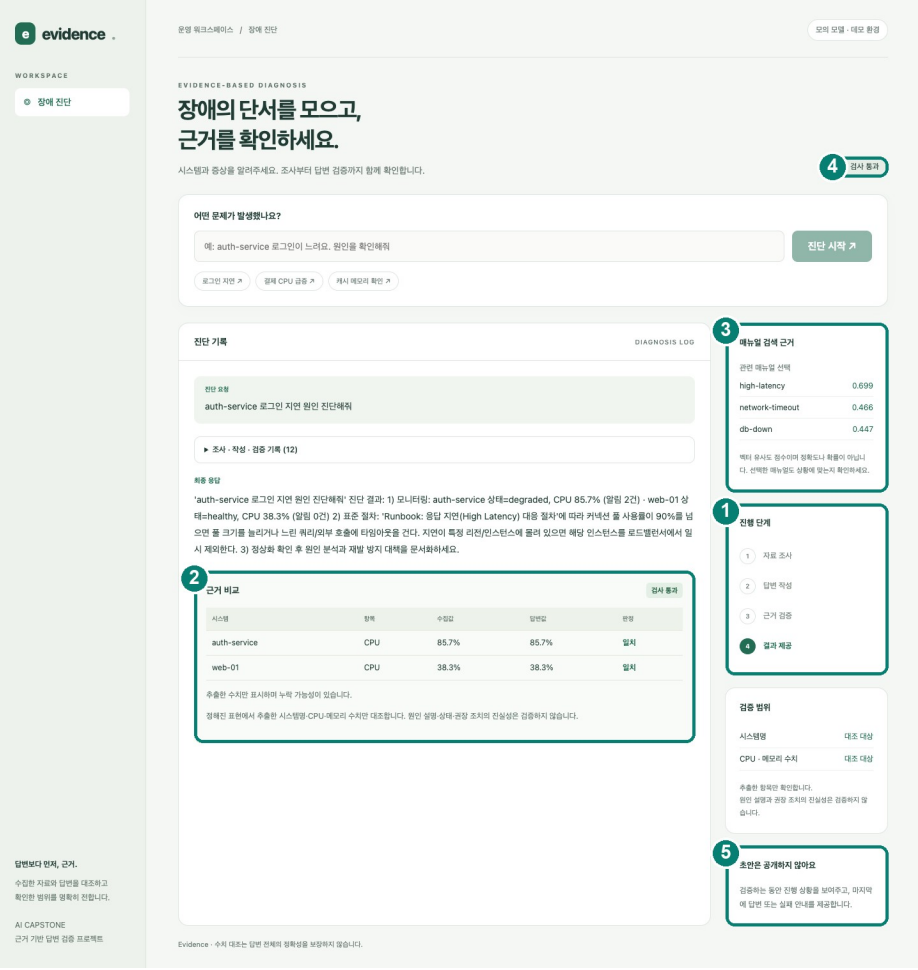
시스템별 수치를 나란히 대조

03 **검증 범위**

확인한 항목과 한계를 명시

모의 작성 모델 · 교육용 모니터링 샘플
실제 MCP·로컬 임베딩 연결 · 2026-10-21

근거 확인 중심의 화면 개선



01 진행 단계
처리 중인 작업을 단계별로 표시

02 수집값 ↔ 답변값
수집값과 답변값을 직접 비교

03 검색 후보 · 유사도
선택된 매뉴얼과 유사도 점수 확인

04 상태 구분
정상 · 검증 실패 · 자료 부족 상태를 구분하여 안내

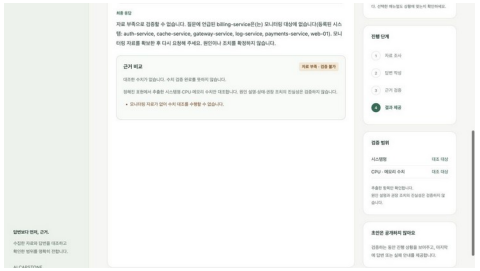
05 초안 비공개
검증 전 초안 비공개

제공받은 Vue 화면을 근거 확인 중심으로 개선 · 모의 작성 모델

검증 실패



자료 부족 · 검증 불가



동일 오류 조건에서 오답 통과 대신 실패 안내

BEFORE

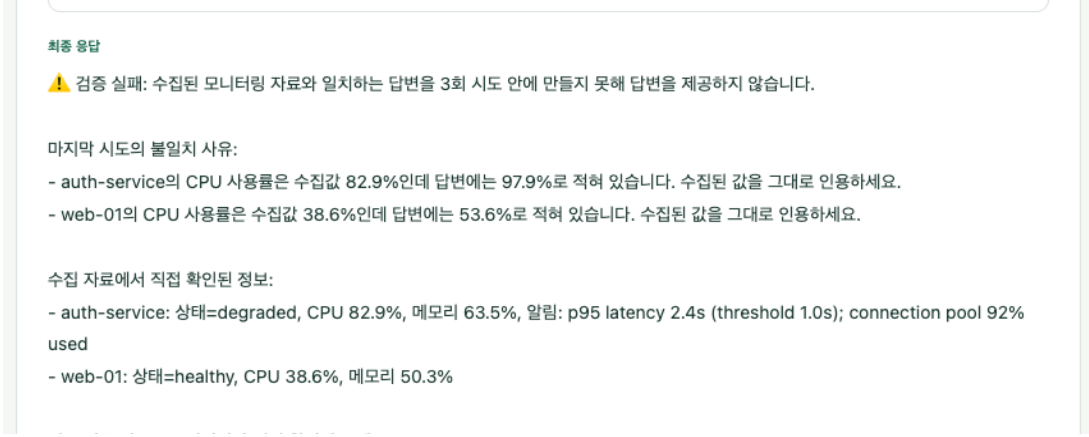
틀린 수치도 통과



검사 기준: 길이·번호

AFTER

수집값과 다르면 차단



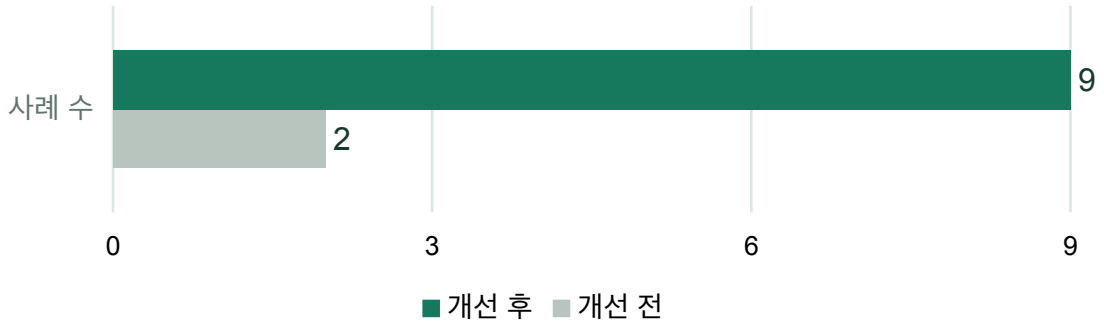
총 3회 실패 → 사유와 실제 수집값 제공

같은 질문 + CPU 수치에 15%p 오류 주입 · 모의 모델 재현 · 실행별 모니터링 수치에는 변동이 있음

자체 평가 기준 오류 차단 및 매뉴얼 선택 개선

오류 답변 차단

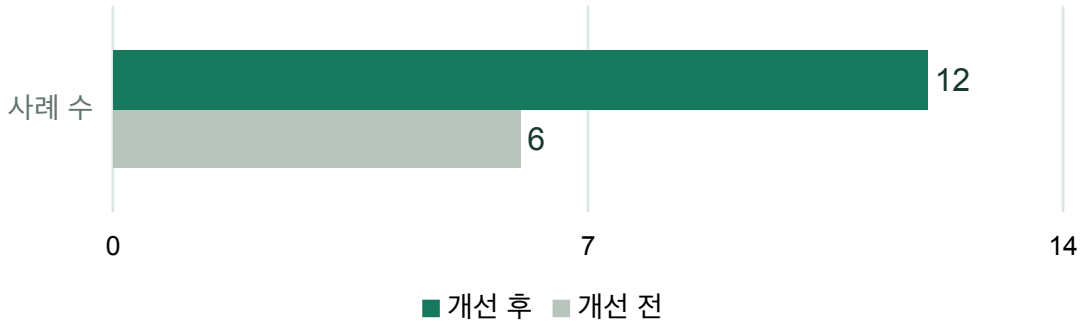
2/9 → 9/9



정상 답변 8/8 유지 · 동일 17개 입력

매뉴얼 선택 기대 일치

6/14 → 12/14



장애 12개 + 무관 질문 2개

소규모 자체 평가 | Ollama 최신 비교: 작성 시도 1.0 → 1.0회, 42.6 → 43.3초 — 속도 향상 주장 안 함

측정 결과 및 기술 선택 근거

측정 결과

작성 모델 호출 생략 (근거 0건)

36.6초 → 1.2~2.7초

단일 질문 실측 · 작성 호출 1회 → 0회

병렬 조사 (모니터링 3건)

1.07초 → 0.36초

제공 구조를 측정 · 작업당 0.35초는 모의 지연

평균 재작성 횟수

2.0회 → 1.0회

비용 절감 지표이며 정확도 향상은 아님

기술 선택 이유와 한계

의미 기반 검색

이유: 키워드는 표현이 다르면 놓침

한계: 임베딩 자원과 지연

규칙 기반 검증

이유: 판정이 명확하고 재현 가능

한계: 새 표현을 놓칠 수 있음

초안 비공개

이유: 틀린 수치의 노출 방지

한계: 최종 답변까지 대기 (토큰 스트리밍 포기)

서브그래프 · 모듈화

이유: 부분 실패 격리, 테스트 용이

한계: 속도 이득은 없음

비용은 글자 수 기반 추정 | 프롬프트 압축·요약은 미적용 | fast/quality 모델 분리와 병렬 구조는 제공 기반을 측정한 것

검증 통과가 답변 전체의 정확성을 보장하지 않음

검증 범위	시스템명·CPU·메모리만 대조	↔	원인 설명·권장 조치는 미검증
표현과 평가	명확한 규칙, 재현 가능한 판정	↔	새 표현 누락 · 자체 평가의 낙관 가능성
사용 경험	초안 비공개 · 의미 기반 검색	↔	최종 답변 대기 · 임베딩 자원과 지연

확인 범위를 명시하고, 근거가 부족하면 응답을 중단하는 방향으로 개선

다음 단계: 독립 평가셋 · 구조화된 수치 출력 · 불분명한 대상은 되묻기