근거 기반
장애 진단 에이전트 개선

수집한 자료와 다른 답변을
그대로 통과시키지 않도록

검증 · 검색 · 조사 안정성

김하연

AI Capstone | 2026.10

질문

**“로그인이 느려요.
원인을 진단해줘.”**

자료 수집 → 근거 대조

일치하면 응답 · 부족하면 중단

형식 검증만으로는 수치 오류를 걸러내지 못함

수집한 자료	모델이 쓴 답변	기존 검증 결과
auth-service · CPU	auth-service · CPU	통과
40%	99%	길이 + 번호만 확인

설명용 예시 · 실제 평가 수치 아님

형식 검사 30자 이상 + “1)” 포함

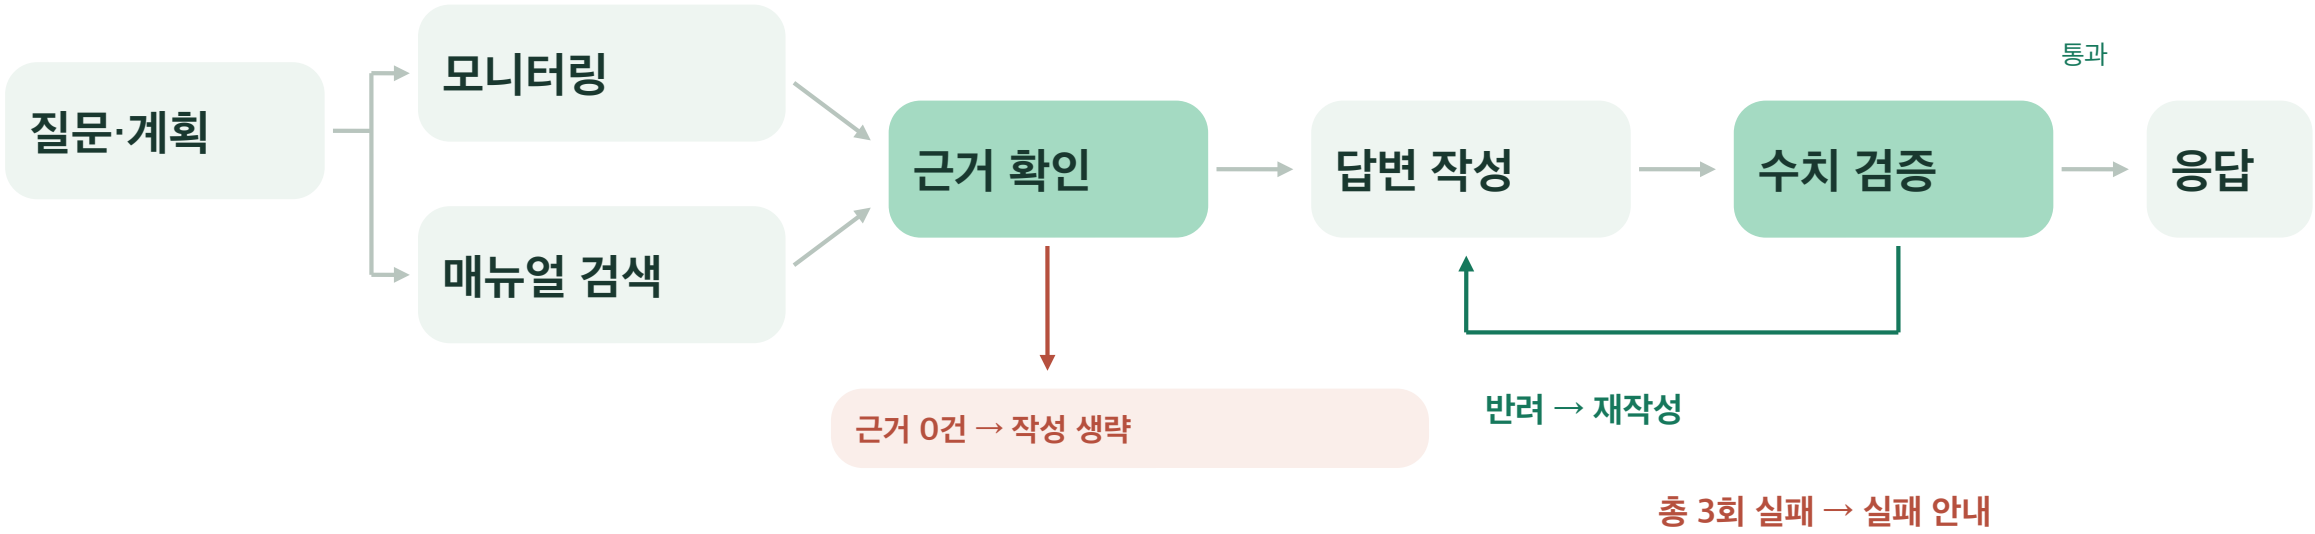
3회 실패해도 강제 합격

근거 수집부터 답변 출력까지 전 구간 개선

검증	길이·번호 확인	→	**시스템별 수치 대조** 불일치 사유 → 재작성 / 총 3회 실패 → 중단
검색	키워드·기본값 선택	→	**매뉴얼 의미 검색** 점수가 낮거나 후보 차이가 작으면 선택 보류
조사	한 작업 실패 시 중단	→	**성공한 자료 유지** 실패 대상 안내 / 근거 0건이면 작성 생략

추가 보완 대상 시스템명 구분 · 역할별 모듈 분리 · 단위·회귀 테스트

근거 확인 및 실패 분기를 반영한 처리 흐름



Multi-Agent

조사 서브그래프 2개
독립 LLM 추론·협상은 아님

MCP · RAG

도구 연결 → 의미 검색
선택한 본문으로 답변 작성

모듈화 · 의존성 주입

역할 분리 · 테스트 도구 교체
단위·회귀 테스트 포함 6종

제공 기반: LangGraph·서버·세션 | 직접 개선: 조사 분리·검색·검증·실패 분기 | LangSmith: 실행 추적만 확인

최종 답변과 확인 근거를 함께 제공

최종 응답

'auth-service 로그인 지연 원인 진단해줘' 진단 결과: 1) 모니터링: auth-service 상태=degraded, CPU 84.0% (알림 2건) · web-01 상태=healthy, CPU 40.3% (알림 0건) 2) 표준 절차: 'Runbook: 응답 지연 (High Latency) 대응 절차'에 따라 커넥션 풀 사용률이 90%를 넘으면 풀 크기를 늘리거나 느린 쿼리/외부 호출에 타임아웃을 건다. 지연이 특정 리전/인스턴스에 몰려 있으면 해당 인스턴스를 로드밸런서에서 일시 제외한다. 3) 정상화 확인 후 원인 분석과 재발 방지 대책을 문서화하세요.

근거 비교 검사 통과

시스템	항목	수집값	답변값	판정
auth-service	CPU	84%	84%	일치
web-01	CPU	40.3%	40.3%	일치

추출한 수치만 표시하며 누락 가능성이 있습니다.

정해진 표현에서 추출한 시스템명·CPU·메모리 수치만 대조합니다. 원인 설명·상태·권장 조치의 진실성은 검증하지 않습니다.

01 **최종 답변**

초안 비공개, 검증 후 제공

02 **수집값 ↔ 답변값**

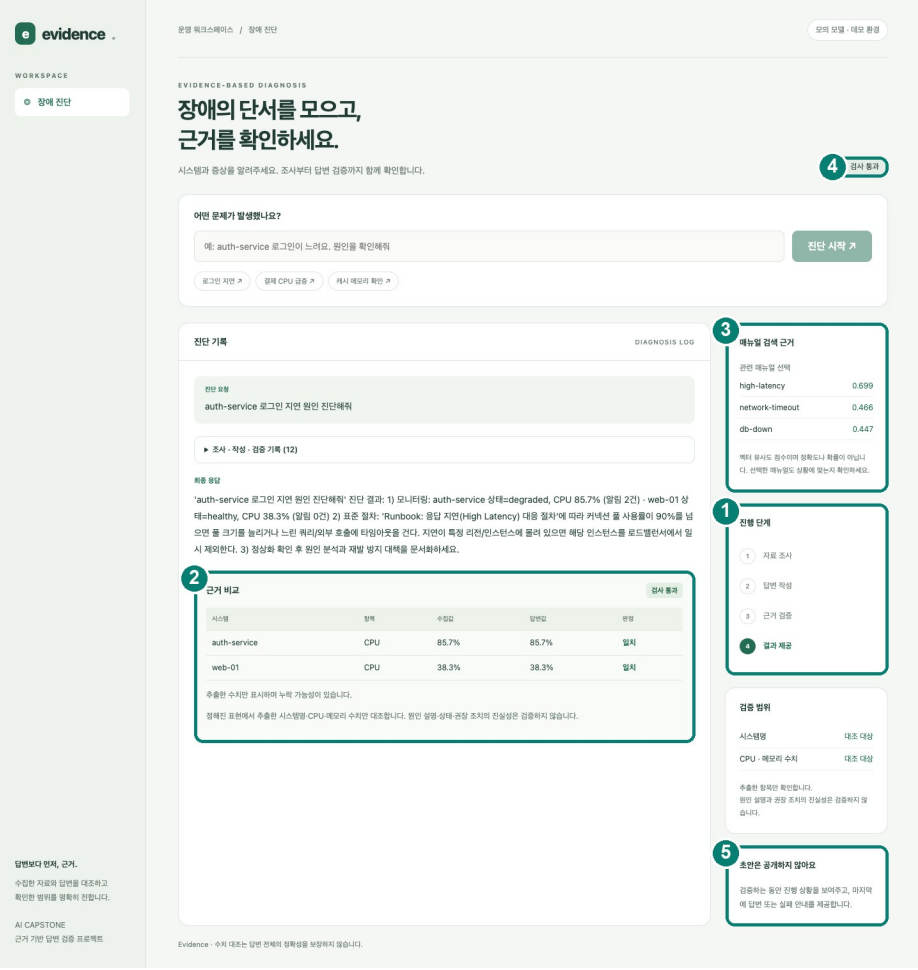
시스템별 수치를 나란히 대조

03 **검증 범위**

확인한 항목과 한계를 명시

모의 작성 모델 · 교육용 모니터링 샘플
실제 MCP·로컬 임베딩 연결 · 2026-10-21

근거 확인 중심의 화면 개선



01 진행 단계
처리 중인 작업을 단계별로 표시

02 수집값 ↔ 답변값
수집값과 답변값을 직접 비교

03 검색 후보 · 유사도
선택된 매뉴얼과 유사도 점수 확인

04 상태 구분
정상 · 검증 실패 · 자료 부족 상태를 구분하여 안내

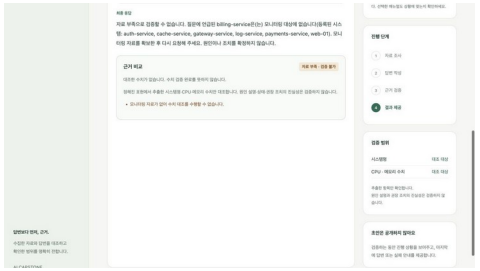
05 초안 비공개
검증 전 초안 비공개

제공받은 Vue 화면을 근거 확인 중심으로 개선 · 모의 작성 모델

검증 실패



자료 부족 · 검증 불가



동일 오류 조건에서 오답 통과 대신 실패 안내

BEFORE

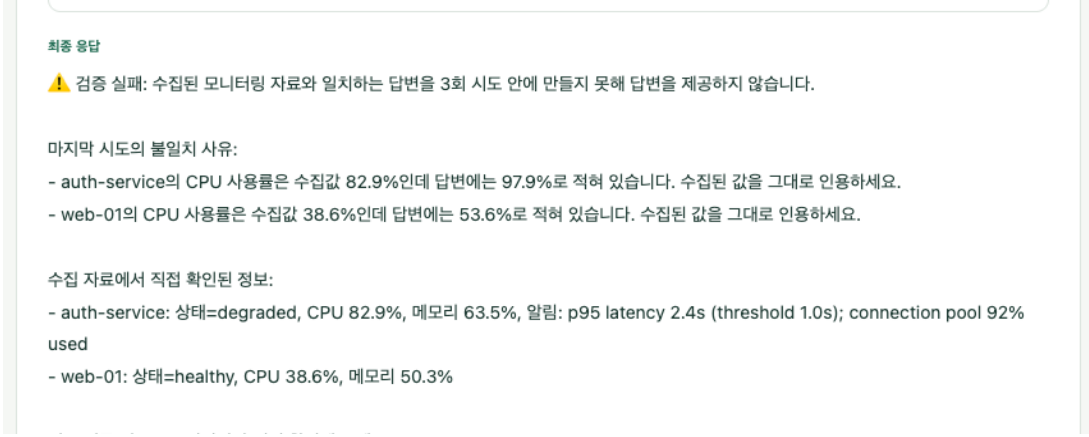
틀린 수치도 통과



검사 기준: 길이·번호

AFTER

수집값과 다르면 차단



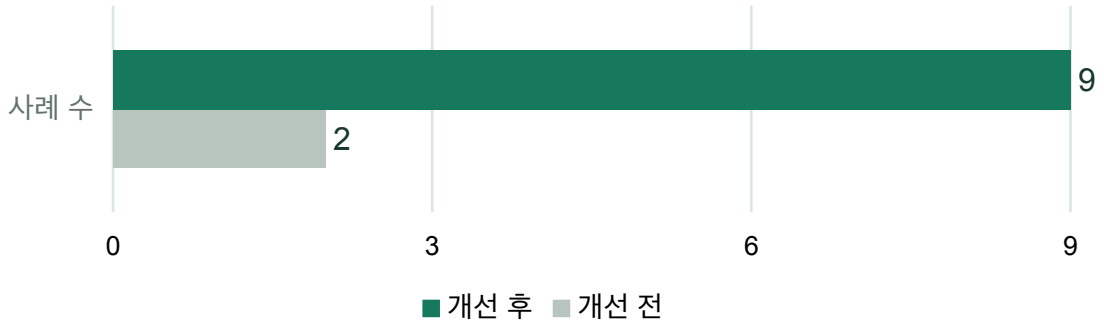
총 3회 실패 → 사유와 실제 수집값 제공

같은 질문 + CPU 수치에 15%p 오류 주입 · 모의 모델 재현 · 실행별 모니터링 수치에는 변동이 있음

자체 평가 기준 오류 차단 및 매뉴얼 선택 개선

오류 답변 차단

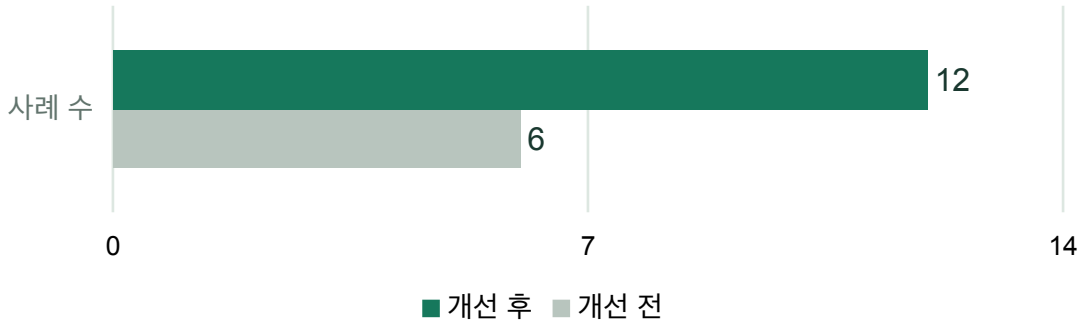
2/9 → 9/9



정상 답변 8/8 유지 · 동일 17개 입력

매뉴얼 선택 기대 일치

6/14 → 12/14



장애 12개 + 무관 질문 2개

소규모 자체 평가 | Ollama 최신 비교: 작성 시도 1.0 → 1.0회, 42.6 → 43.3초 — 속도 향상 주장 안 함

측정 결과 및 기술 선택 근거

측정 결과 (전 → 후)

작성 모델 호출 생략 (근거 0건)

13배 이상 단축



단일 질문 실측 · 작성 호출 1회 → 0회

병렬 조사 (모니터링 3건)

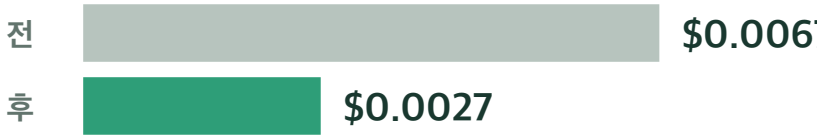
약 2.9배 단축



제공 구조 측정 · 작업당 0.35초는 모의 지연

모델 분리 비용 (fast/quality)

약 59% 절감



글자 수 기반 추정 · 제공 구조 측정

기술 선택 이유와 한계

기술	선택 이유	한계
의미 기반 검색	키워드는 표현이 다르면 놓침	임베딩 자원 · 지연
규칙 기반 검증	판정이 명확 · 재현 가능	새 표현 누락 가능
초안 비공개	틀린 수치 노출 방지	답변 대기 · 토큰 스트리밍 포기
서브그래프 · 모듈화	부분 실패 격리 · 테스트 용이	속도 이득 없음

비용은 글자 수 기반 추정 | 프롬프트 압축·요약은 미적용 | fast/quality 모델 분리와 병렬 구조는 제공 기반을 측정한 것

검증 통과가 답변 전체의 정확성을 보장하지 않음

검증 범위	시스템명·CPU·메모리만 대조	↔	원인 설명·권장 조치는 미검증
표현과 평가	명확한 규칙, 재현 가능한 판정	↔	새 표현 누락 · 자체 평가의 낙관 가능성
사용 경험	초안 비공개 · 의미 기반 검색	↔	최종 답변 대기 · 임베딩 자원과 지연

확인 범위를 명시하고, 근거가 부족하면 응답을 중단하는 방향으로 개선

다음 단계: 독립 평가셋 · 구조화된 수치 출력 · 불분명한 대상은 되묻기

부록

발표는 앞 장(10/10)에서 마칩니다. 아래는 질의응답과 결과 확인용 근거 자료입니다.

A-1	기술 요소 15개와 구현 위치	제공 기반 · 직접 구현 · 측정 구분
A-2	설계 결정 15개 (ADR)	결정 구분과 비용·한계
A-3	평가 방법과 결과	평가셋별 전후 수치와 해석상 주의
A-4	검증 규칙과 실패 처리	읽는 표현 · 제외 규칙 · 종료 조건
A-5	재현 방법과 근거 자료	저장소 · 실행 명령 · 근거 파일

기술 요소 15개와 구현 위치

요소	구분	구현 위치 · 근거
ADR	직접	doc/ADR.md · 설계 결정 15개
FastAPI · SSE 백엔드	제공	server.py · /chat, /chat/stream, /health
MCP Server	제공 + 직접	모니터링·매뉴얼 제공 / 검색 도구 직접 추가
SSE 프론트엔드	제공 + 직접	Vue EventSource 제공 / 근거 표시 화면 직접 개선
Multi-Agent Streaming	트레이드오프	진행 이벤트만 전송, 초안 토큰은 차단 (ADR-04)
Query Routing · Dynamic Planning	제공	route · plan · replan_check 노드
Validator	직접	agent/verifier.py · validate · finalize_failed
Error Handling	제공 + 직접	재시도·타임아웃 제공 / 실패 격리·검증 실패 종료 직접
Cost Optimization	제공 + 직접	fast/quality 분리 제공 / 근거 0건 시 작성 생략 직접
동시 실행	제공 · 측정	asyncio.gather · 직렬 1.07초 → 병렬 0.36초
Stateless Session	제공	SQLite thread_id 세션
모듈화	직접	graph.py 425줄 → 58줄, nodes/ 6개 모듈
Multi-Agent 통합	직접 (얕은 형태)	서브그래프 2개 · LLM 판단·협상 없음
Observability (LangSmith)	직접 활용	추적 1회 실행, 59개 run 확인 · 비교 평가는 미수행
의존성 주입 · 테스트	직접	SupervisorDeps 주입 · 테스트 6종

설계 결정 15개 (ADR)

번호	결정	구분	비용 · 한계
01	수치 검증을 규칙 기반으로 분리	직접	오탐·누락 가능, 원인 설명은 검증 안 함
02	로컬 임베딩 의미 검색	직접	모델 639MB · Ollama 의존, 오선택 1건
03	병렬 조사 실패 격리	직접	부분 결과가 완전한 진단처럼 보일 위험
04	초안 비공개 · 근거 표시 화면	직접	최종 답변까지 대기
05	LangGraph 상태 그래프	제공	분기가 코드 곳곳에 분산
06	SSE 단방향 진행 스트리밍	제공	답변 본문은 완료 후 한 번에 출력
07	세션을 SQLite에 저장	제공	다중 서버 확장에는 부적합
08	모델을 fast/quality로 분리	제공 · 측정	글자 수 기반 추정, 단가는 가정값
09	조사를 동시 실행	제공 · 측정	0.35초 고정 지연은 모의 값
10	조사 서브에이전트 분리	직접	속도 이득 없음 · LLM 판단 아님
11	대상 시스템을 코드가 해석	직접	정규식 의존 · 되묻기가 아니라 알림
12	검증기 2차 (표현 범위 확대)	직접	표적 사례 중심이라 수치가 낙관적
13	그래프 노드를 모듈로 분리	직접	파일 수 증가 · 수치로 증명하지 않음
14	근거 0건이면 작성 모델 호출 생략	직접	0건일 때만 동작
15	의미 검색의 비용·지연 측정	측정	콜드 첫 검색 약 1.1초, 웜 약 29ms

평가 방법과 결과

평가	결과 (개선 전 → 후)	해석상 주의
동일 17개 입력 (정상 8·오류 9)	오류 차단 2/9 → 9/9 · 정상 통과 8/8 유지	입력은 같고 검증기만 교체
검증 규칙 표적 사례 28개	오류 차단 6/14 → 14/14 · 정상 7/14 → 14/14	약점을 겨냥해 만든 사례라 낙관적
설계 때 보지 못한 변형 6개	오류 차단 4/5 → 5/5	표본이 작아 일반화 근거로 약함
부작용·회귀 탐침 8개	정상 1/4 → 4/4 · 오류 3/4 → 4/4	수정 후 회귀 방지용
매뉴얼 검색 14개 (장애 12·무관 2)	기대 일치 6/14 → 12/14	미확정 1건 · 오선택 1건 · 직접 작성
대상 시스템 해석 8개	목록에 없는 시스템이 auth-service로 바뀌던 사례 해소	계획 정규화는 스텁 모델 출력 기준
근거 없는 질문 (Ollama 3회)	응답 36.6초 → 1.2~2.7초 · 작성 호출 1 → 0회	단일 질문 · 근거 0건일 때만
실모델 Ollama (4문항 × 1회)	작성 시도 1.0 → 1.0회 · 42.6 → 43.3초	실행 간 변동 커서 개선을 주장하지 않음

평가 원칙: 규칙을 고치기 전에 사례를 먼저 만들고, 개선 전 검증기를 스냅샷으로 보관해 같은 입력으로 비교했다.

한계: 사례를 만든 사람과 구현한 사람이 같아 낙관적일 수 있고, 독립 평가셋과 LangSmith 비교 평가는 하지 않았다.

검증 규칙과 실패 처리

검증 규칙 (verifier.py)

- 시스템명 · CPU · 메모리 수치를 수집값과 대조
- 반올림을 고려해 0.5%p 이하 차이는 허용
- 동의어 · 숫자가 먼저 오는 문장 · 표 · '각각' · 영어 서술을 읽음
- 임계치 · 조건문 · 부정된 수치는 측정 주장에서 제외 (부정 뒤 수치는 대조)
- 조회하지 못한 시스템의 수치를 주장하면 반려
- 시스템명은 수치를 인용할 때만 요구
- 최초 작성 포함 3회 불일치 시 종료

실패 처리

- 모니터링 도구는 재시도하고 15초 제한, 의미 검색은 60초 제한
- 작업별 예외를 격리해 성공한 자료를 유지, 취소 신호는 전파
- 실패한 대상은 이벤트와 최종 답변에 한계로 표시
- 근거가 0건이면 작성을 생략하고 '자료 부족 · 검증 불가'로 종료
- 3회 불일치 시 강제 합격 대신 사유와 수집값을 안내
- 목록에 없는 시스템은 다른 시스템으로 바꾸지 않고 조사 실패로 안내

알려진 한계: 수치를 직전에 나온 시스템명에 연결해서, 조회하지 못한 시스템 설명 뒤에 다른 시스템 수치가 오면 정상 서술도 반려될 수 있고 'customer-service', 'top-10' 같은 일반 표현을 시스템으로 오인한다.

재현 방법과 근거 자료

공개 저장소

github.com/gkyeon/ai-capstone-gkyeon

이 저장소만으로 재현되는 것

```
python3 eval/eval_verifier_v2.py
```

검증기 개선 전후 42개 사례 비교

수업 제공 프로젝트가 필요한 것

나머지 평가와 화면 실행

저장소에는 제공 코드를 넣지 않았고, 저장된 결과 파일로 확인할 수 있음

근거	파일
17개 입력 · 그래프 전체 실행	eval/results.md
검증기 개선 전후 기준선	eval/baseline/ · eval_verifier_v2.py
매뉴얼 검색 14개	eval/search-evaluation-20261021.json
대상 시스템 해석 전후	eval/targets-*-20261021.json
실모델(Ollama) 실행 원본	eval/ollama-live-20261021*.json
근거 0건 조기 종료	eval/ollama-live-evidence-gate-*.json
병렬 · 비용 · 임베딩 측정	eval/bonus-measure-*.md, embedding-cost-*.md
설계 결정 · 결과보고서	doc/ADR.md · submission/결과보고서.md