근거 기반
장애 진단 에이전트 개선

수집한 자료와 다른 답변을
그대로 통과시키지 않도록

검증 · 검색 · 조사 안정성

김하연

AI Capstone | 2026.10

질문

**“로그인이 느려요.
원인을 진단해줘.”**

자료 수집 → 근거 대조

일치하면 응답 · 부족하면 중단

형식은 맞아도, 수치는 틀릴 수 있었다

수집한 자료

auth-service · CPU

40%

→

모델이 쓴 답변

auth-service · CPU

99%

→

기존 검증 결과

통과

길이 + 번호만 확인

설명용 예시 · 실제 평가 수치 아님

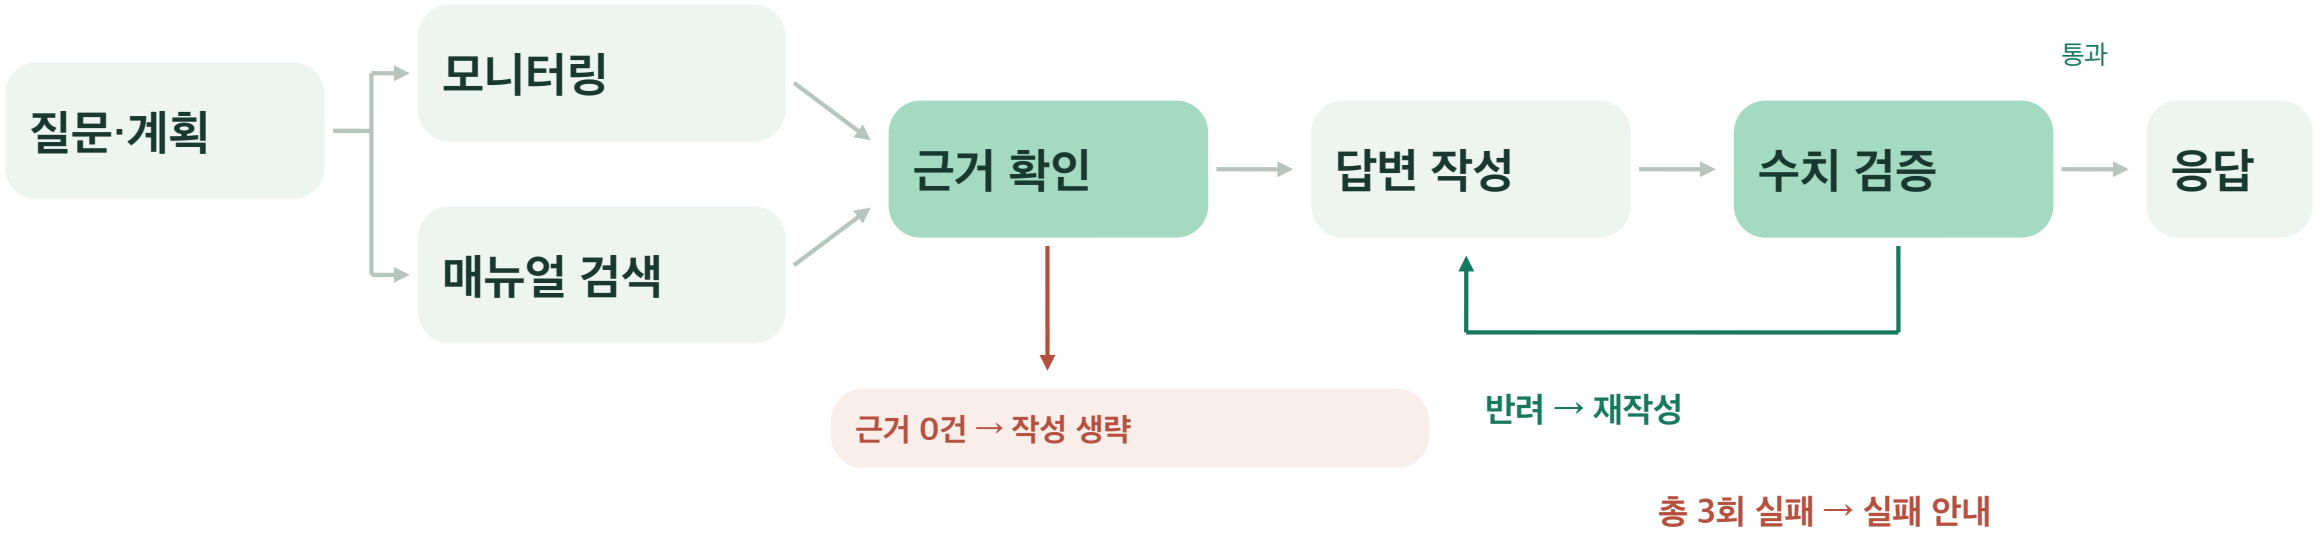
형식 검사 30자 이상 + “1)” 포함 **3회 실패해도 강제 합격**

근거를 모으는 과정부터, 답변을 내보내기까지

검증	길이·번호 확인	→	**시스템별 수치 대조** 불일치 사유 → 재작성 / 총 3회 실패 → 중단
검색	키워드·기본값 선택	→	**매뉴얼 의미 검색** 점수가 낮거나 후보 차이가 작으면 선택 보류
조사	한 작업 실패 시 중단	→	**성공한 자료 유지** 실패 대상 안내 / 근거 0건이면 작성 생략

추가 보완 대상 시스템명 구분 · 역할별 모듈 분리 · 단위·회귀 테스트

근거 확인과 실패 분기를 처리 흐름에 넣었다



Multi-Agent

조사 서브그래프 2개
독립 LLM 추론·협상은 아님

MCP · RAG

도구 연결 → 의미 검색
선택한 본문으로 답변 작성

모듈화 · 의존성 주입

역할 분리 · 테스트 도구 교체
단위·회귀 테스트 포함 6종

제공 기반: LangGraph·서버·세션 | 직접 개선: 조사 분리·검색·검증·실패 분기 | LangSmith: 실행 추적만 확인

최종 답변 옆에, 확인한 근거를 남겼다

최종 응답

'auth-service 로그인 지연 원인 진단해줘' 진단 결과: 1) 모니터링: auth-service 상태=degraded, CPU 84.0% (알림 2건) · web-01 상태=healthy, CPU 40.3% (알림 0건) 2) 표준 절차: 'Runbook: 응답 지연 (High Latency) 대응 절차'에 따라 커넥션 풀 사용률이 90%를 넘으면 풀 크기를 늘리거나 느린 쿼리/외부 호출에 타임아웃을 건다. 지연이 특정 리전/인스턴스에 몰려 있으면 해당 인스턴스를 로드밸런서에서 일시 제외한다. 3) 정상화 확인 후 원인 분석과 재발 방지 대책을 문서화하세요.

근거 비교 검사 통과

시스템	항목	수집값	답변값	판정
auth-service	CPU	84%	84%	일치
web-01	CPU	40.3%	40.3%	일치

추출한 수치만 표시하며 누락 가능성이 있습니다.

정해진 표현에서 추출한 시스템명·CPU·메모리 수치만 대조합니다. 원인 설명·상태·권장 조치의 진실성은 검증하지 않습니다.

01 **최종 답변**

초안은 숨기고 처리 후 제공

02 **수집값 ↔ 답변값**

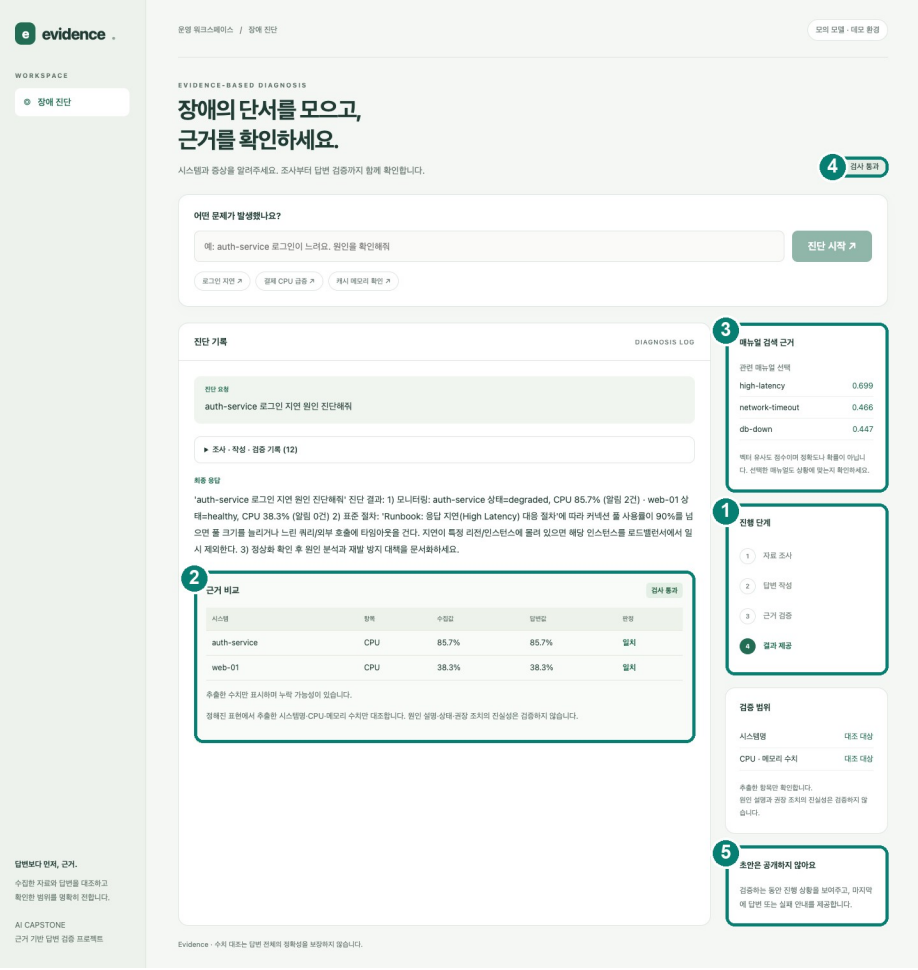
시스템별 수치를 나란히 대조

03 **검증 범위**

확인한 항목과 한계를 명시

모의 작성 모델 · 교육용 모니터링 샘플
실제 MCP·로컬 임베딩 연결 · 2026-10-21

화면도 근거를 확인하는 방향으로 고쳤다



01 진행 단계
기다리는 동안 하는 일이 보인다

02 수집값 ↔ 답변값
통과했다는 말만 믿지 않고 직접 비교한다

03 검색 후보 · 유사도
선택된 매뉴얼과 점수를 확인한다

04 상태 구분
정상 · 검증 실패 · 자료 부족을 다르게 안내한다

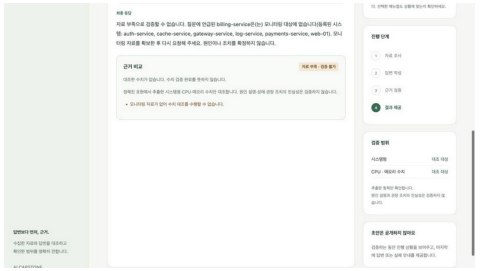
05 초안 비공개
반려될 초안은 먼저 보여주지 않는다

제공받은 Vue 화면을 근거 확인 중심으로 개선 · 모의 작성 모델

검증 실패



자료 부족 · 검증 불가



같은 오류 조건에서, 통과 대신 실패를 안내했다

BEFORE

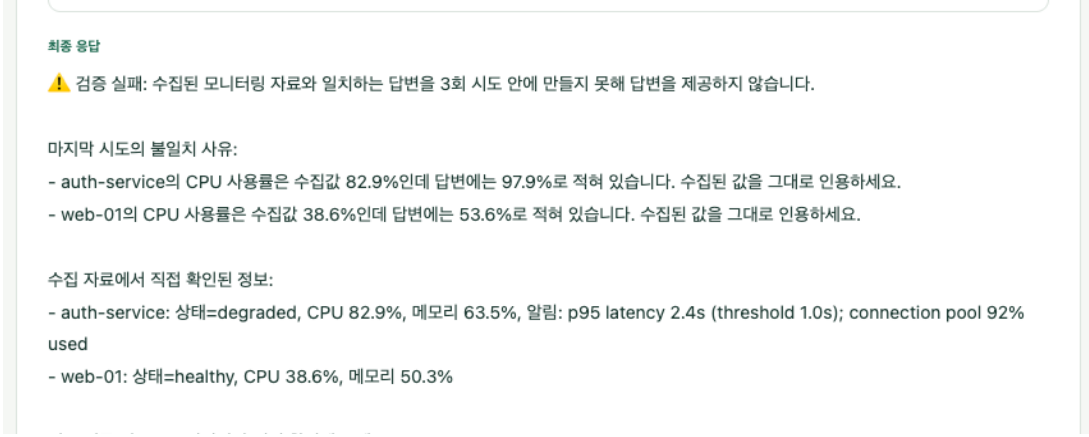
틀린 수치도 통과



검사 기준: 길이·번호

AFTER

수집값과 다르면 차단



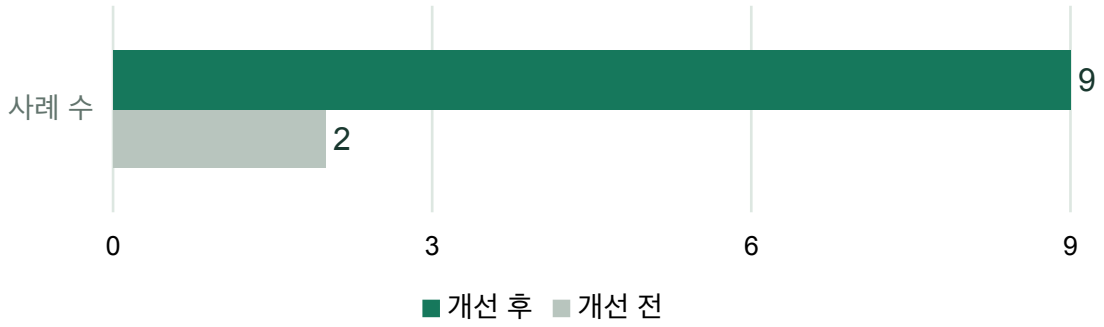
총 3회 실패 → 사유와 실제 수집값 제공

같은 질문 + CPU 수치에 15%p 오류 주입 · 모의 모델 재현 · 실행별 모니터링 수치에는 변동이 있음

자체 평가에서 오류 차단과 검색 선택을 개선했다

오류 답변 차단

2/9 → 9/9



정상 답변 8/8 유지 · 동일 17개 입력

매뉴얼 선택 기대 일치

6/14 → 12/14



장애 12개 + 무관 질문 2개

소규모 자체 평가 | Ollama 최신 비교: 작성 시도 1.0 → 1.0회, 42.6 → 43.3초 — 속도 향상 주장 안 함

검사 통과가 답변 전체의 진실성을 뜻하지는 않는다

검증 범위	시스템명·CPU·메모리만 대조	↔	원인 설명·권장 조치는 미검증
표현과 평가	명확한 규칙, 재현 가능한 판정	↔	새 표현 누락 · 자체 평가의 낙관 가능성
사용 경험	초안 비공개 · 의미 기반 검색	↔	최종 답변 대기 · 임베딩 자원과 지연

확인한 범위를 보여주고, 근거가 부족하면 멈추도록.

다음 단계: 독립 평가셋 · 구조화된 수치 출력 · 불분명한 대상은 되묻기